

Rencana Teknis Pengembangan Asisten Belajar Berbasis Korpus Buku Sekolah

Arsitektur Retrieval-Augmented Generation dan Fine-Tuning di atas SEA-LION 8B

Atribut	Keterangan
Korpus	Sekitar 10.000 buku sekolah jenjang SD, SMP, dan SMA, total sekitar 5 GB
Model dasar	Qwen-SEA-LION-v4-8B-VL (basis Qwen3-VL-8B-Instruct, jendela konteks 256K)
Platform RAG	RantAI Agents, fitur <i>knowledge base</i>
Platform pelatihan	RantAI LLMOps (<i>supervised fine-tuning</i> dan evaluasi) di atas NVIDIA DGX Spark (GB10)
Metode pelatihan	LoRA BF16 sebagai jalur utama (QLoRA tidak dipakai di GB10, lihat 6.3)
Penyimpanan korpus	Object storage S3-compatible (MinIO) di server, sumber tunggal untuk RAG dan pelatihan
Status dokumen	Versi 2, Juli 2026

1. Ringkasan Eksekutif

Dokumen ini merinci rencana pengembangan asisten belajar untuk siswa SD, SMP, dan SMA yang dibangun di atas korpus sekitar 10.000 buku sekolah. Sistem dirancang agar menghasilkan jawaban yang akurat, menyertakan sitasi sumber pada tingkat buku dan bab, menyesuaikan register bahasa dengan jenjang pengguna, serta dapat beroperasi secara *on-premise* untuk memenuhi kebutuhan kedaulatan data.

Prinsip arsitektur utama dokumen ini adalah pemisahan tegas antara pengetahuan dan perilaku. Seluruh isi buku dikelola melalui jalur *retrieval-augmented generation* (RAG) pada fitur *knowledge base* RantAI Agents. *Fine-tuning* hanya digunakan untuk membentuk perilaku model, yaitu persona pengajar, format jawaban, kedisiplinan sitasi, dan penolakan menjawab ketika konteks tidak memadai. Pendekatan ini dipilih karena penyimpanan fakta di dalam bobot model 8 miliar parameter tidak dapat diandalkan, tidak dapat menghasilkan sitasi yang terverifikasi, dan menuntut pelatihan ulang setiap kali isi buku berubah.

2. Tujuan dan Kriteria Keberhasilan

2.1 Tujuan

- Menyediakan asisten tanya jawab materi pelajaran yang jawabannya selalu berlandaskan isi buku resmi di dalam korpus.
- Menjamin setiap jawaban menyertakan sitasi sumber pada tingkat judul buku dan bab.
- Menyesuaikan gaya bahasa jawaban dengan jenjang pengguna, dari SD hingga SMA.
- Memastikan pembaruan korpus, misalnya revisi kurikulum, dapat dilakukan tanpa pelatihan ulang model.

2.2 Kriteria keberhasilan

- Akurasi jawaban ber-sitasi mencapai target evaluasi pada ketiga jenjang.
- Model menolak menjawab secara tepat ketika konteks hasil *retrieval* tidak relevan.
- Tidak terjadi kebocoran cakupan antar jenjang, misalnya siswa SD menerima konteks dari buku SMA.
- Tidak ada konten yang tidak pantas bagi anak yang lolos dari lapisan penyaring.
- Penambahan atau revisi buku cukup melalui proses *re-embedding*, tanpa pelatihan ulang.

3. Arsitektur Sistem

3.1 Pembagian lapisan

Lapisan	Solusi	Cakupan
Pengetahuan	RAG pada <i>knowledge base</i> RantAI Agents	Seluruh isi korpus. Pembaruan dilakukan melalui <i>re-embedding</i> dokumen terkait tanpa menyentuh bobot model.
Perilaku	SFT metode LoRA BF16 melalui RantAI LLMOps di GB10	Persona pengajar, format jawaban per jenjang, kewajiban sitasi, serta penolakan saat konteks kosong.
Model	Qwen-SEA-LION-v4-8B-VL	Jendela konteks 256K untuk menampung banyak potongan hasil <i>retrieval</i> . Kemampuan OCR bahasa Indonesia dimanfaatkan pada tahap praproses.

3.2 Struktur *knowledge base*

Fitur *knowledge base* pada RantAI Agents saat ini bersifat datar, belum mendukung folder bersarang. Struktur yang diterapkan adalah **satu *knowledge base* untuk setiap kelas**, sehingga total terdapat dua belas *knowledge base* dengan konvensi penamaan sebagai berikut.

```
sdkelas1, sdkelas2, ..., sdkelas6   (6 KB jenjang SD)
smpkelas7, smpkelas8, smpkelas9     (3 KB jenjang SMP)
smakelas10, smakelas11, smakelas12 (3 KB jenjang SMA)
```

Seluruh buku kelas tiga SD, misalnya, dimasukkan ke dalam *knowledge base* sdkelas3. Pemecahan lebih lanjut per mata pelajaran ditunda. Migrasi ke granularitas per mata pelajaran di kemudian hari hanya memerlukan pemindahan dokumen antar *knowledge base*, tanpa *re-embedding*, selama metadata mata pelajaran telah tercatat sejak tahap inventarisasi.

3.3 Pembatasan cakupan melalui pemilihan *knowledge base*

Daftar *knowledge base* yang boleh diakses ditentukan secara eksplisit pada setiap panggilan API oleh satu fungsi di lapisan aplikasi.

```
resolve_kbs(jenjang, kelas) → [daftar knowledge base]
```

Sebagai contoh, agen untuk siswa SD kelas lima menerima daftar sdkelas1 sampai sdkelas5. Dengan mekanisme ini, *retrieval* secara struktural tidak mungkin menyentuh *knowledge base* di luar daftar, sehingga batas antar jenjang bersifat keras dan dapat diaudit. Kebijakan akses kumulatif, misalnya siswa kelas lima yang boleh mengakses materi kelas satu sampai empat, diatur terpusat pada fungsi yang sama.

3.4 Sitasi melalui kepala potongan

Karena *knowledge base* bersifat datar, metadata dokumen belum tentu terbawa pada hasil *retrieval*. Sebagai jaminan, setiap potongan teks diawali kepala sitasi yang disematkan pada tahap praproses.

```
[Buku IPA Kelas 3, Bab 2: Wujud Benda]
```

Dengan cara ini, informasi sumber selalu tersedia di dalam konteks yang diterima model, terlepas dari perilaku platform, sehingga mekanisme sitasi tidak bergantung pada fitur metadata pihak mana pun.

3.5 Penyimpanan korpus pada *object storage*

Seluruh berkas korpus disimpan pada *object storage* S3-compatible (MinIO) di server sebagai sumber tunggal. Semua konsumen, yaitu pipeline praproses, pemasukan ke *knowledge base*, generator dataset SFT, dan *trainer* di GB10, menarik data dari lokasi yang sama. Tata letak *bucket* mengikuti tahapan pipeline sebagai berikut.

```
s3://buku-korpus/
raw/              berkas asli (PDF/EPUB), tidak pernah ditimpa
processed/        hasil ekstraksi Markdown per buku
chunks/           hasil pemotongan + kepala sitasi, siap ingest
sft/              train.jsonl dan eval.jsonl
catalog/          katalog metadata dari langkah 1.1
```

Tiga ketentuan diberlakukan. Pertama, direktori raw/ bersifat *immutable* dengan *bucket versioning* aktif, sehingga revisi buku masuk sebagai versi baru. Kedua, kunci objek mengikuti metadata, misalnya

raw/sma/kelas-10/fisika/{penerbit}-{judul}.pdf, sehingga jalur berkas membawa informasi jenjang, kelas, dan mata pelajaran. Ketiga, *checksum* setiap berkas dicatat pada katalog untuk deduplikasi dan verifikasi integritas. Karena NVMe internal DGX Spark terbatas, pola kerja pelatihan adalah menarik data dari S3 ke disk lokal per pekerjaan, bukan *streaming* langsung saat pelatihan.

4. Fase 1, Praproses Korpus

Fase ini dikerjakan paling awal karena kualitas praproses menentukan mutu seluruh tahapan di hilir.

Langkah	Uraian
1.1 Inventarisasi dan metadata	Menyusun katalog seluruh 10.000 buku, mencakup judul, penerbit, mata pelajaran, jenjang, kelas, kurikulum (K13 atau Merdeka), dan format berkas. Metadata mata pelajaran wajib tercatat meskipun granularitas KB masih per kelas, karena metadata inilah yang membuka jalur migrasi per mata pelajaran tanpa <i>re-embedding</i> .
1.2 Triase format	Memilah korpus menjadi tiga kelompok, yaitu teks digital bersih yang dapat diekstraksi langsung, PDF hasil pindaian atau berilustrasi berat yang memerlukan OCR melalui model VL, serta berkas rusak atau duplikat yang dibuang dan dicatat. Rasio kelompok pertama terhadap kedua menentukan beban jalur OCR dan wajib dilaporkan sebelum melanjutkan ke langkah berikutnya.
1.3 Ekstraksi dan strukturisasi	Mengonversi setiap buku ke format Markdown dengan struktur bab dan subbab dipertahankan sebagai jangkar sitasi. Tabel dan takarir gambar diekstraksi sebagai teks, sedangkan rumus dinormalisasi.
1.4 Pembersihan	Menghapus kepala dan kaki halaman berulang, nomor halaman, daftar isi mentah, serta halaman sampul. Deduplikasi dilakukan terhadap edisi berbeda dari buku yang sama.
1.5 Pemotongan dan kepala sitasi	Memotong teks menjadi potongan sekitar 500 token mengikuti batas subbab dengan tumpang-tindih 10 sampai 15 persen. Setiap potongan diawali kepala sitasi. Estimasi total sekitar 2,5 juta potongan dari 1 sampai 1,25 miliar token.
1.6 Uji mutu sampel	Audit manual minimal 1 sampai 2 persen sampel per penerbit dan per jenjang sebelum <i>embedding</i> .

5. Fase 2, Pemasukan ke *Knowledge Base*

Hasil pemotongan diunggah ke dua belas *knowledge base* sesuai kelas masing-masing. Setelah pemasukan, dilakukan uji asap *retrieval* dengan 20 sampai 30 kueri per jenjang untuk memverifikasi tiga hal, yaitu relevansi potongan yang terambil, keterbawaan kepala sitasi pada hasil, dan ketiadaan kebocoran cakupan antar jenjang.

6. Fase 3, Dataset SFT dan Pelatihan

6.1 Komposisi dataset

Dataset berbentuk JSONL bergaya percakapan. Kolom masukan berisi konteks hasil *retrieval* beserta pertanyaan siswa, sedangkan kolom keluaran berisi jawaban ideal. Dataset ini melatih cara menjawab, bukan isi buku.

- Dua sampai lima ribu contoh positif, yaitu konteks relevan yang dijawab dengan sitasi dan register bahasa yang dibedakan secara eksplisit untuk jenjang SD, SMP, dan SMA.
- Sepuluh sampai dua puluh persen contoh negatif, yaitu konteks tidak relevan yang dijawab dengan penolakan halus. Komponen ini merupakan penangkal utama halusinasi.
- Variasi lintas mata pelajaran, lintas kelas, pertanyaan dengan salah ketik atau bahasa percakapan anak, serta pertanyaan berbagian banyak.
- Pembagian data latih dan evaluasi sebesar 95 banding 5.

Dataset dihasilkan secara semi-sintetis. Potongan diambil acak dari korpus, kemudian model besar menghasilkan pasangan pertanyaan dan jawaban ideal, lalu 5 sampai 10 persen sampel diperiksa secara manual.

6.2 Konfigurasi pelatihan pada GB10, jalur utama LoRA BF16

Parameter	Nilai
-----------	-------

Perangkat keras	Satu unit NVIDIA DGX Spark (GB10 Grace Blackwell), memori terpadu 128 GB LPDDR5x. Kapasitas ini menampung LoRA BF16 model 8B dengan sangat lega, termasuk sampel panjang berisi konteks <i>retrieval</i> sebesar 1.000 sampai 2.000 token lebih.
Metode	LoRA. Model dasar dimuat penuh pada presisi BF16, adaptor dilatih di atasnya. BF16 dipakai konsisten untuk pelatihan dan inferensi.
Hiperparameter awal	Rank 16 sampai 32, alpha dua kali rank, laju belajar 1e-4 sampai 2e-4, 2 sampai 3 epoch, optimasi AdamW.
Kerangka kerja	Kerangka yang terverifikasi berjalan baik di DGX Spark, yaitu LLaMA-Factory atau Unsloth, sebagai basis integrasi <i>trainer</i> RantAI LLMOps.
Praktik operasional	<i>Checkpointing</i> berkala setiap 2 sampai 3 jam sesi. Estimasi durasi untuk skala dataset ini berkisar beberapa jam sampai satu malam, mengingat lebar pita memori GB10 lebih rendah daripada GPU diskret ber-HBM.

6.3 Alasan QLoRA tidak dipakai di GB10

Pada rencana versi sebelumnya, QLoRA dipilih karena keterbatasan VRAM 24 GB. Batasan tersebut tidak berlaku pada memori terpadu 128 GB, sehingga kuantisasi 4-bit hanya menambah beban komputasi tanpa manfaat memori. Selain itu, terdapat laporan komunitas mengenai kemacetan kernel QLoRA 4-bit pada arsitektur sm_121 milik GB10 yang menyebabkan pelatihan nyaris berhenti. Oleh karena itu, QLoRA dikeluarkan dari rencana, bukan sekadar diturunkan menjadi alternatif.

6.4 Catatan platform

Perlu diverifikasi bahwa *trainer* pada RantAI LLMOps mendukung arsitektur Qwen3-VL. Apabila belum, jalur cadangan adalah *fine-tuning* varian teks (Qwen3-8B atau SEA-LION varian teks), mengingat dataset SFT memang sepenuhnya berbasis teks.

7. Fase 4, Evaluasi dan Lapisan Pengaman

- Evaluasi akurasi faktual ber-sitasi per jenjang terhadap set evaluasi yang disisihkan.
- Pengukuran tingkat penolakan yang tepat ketika konteks kosong atau tidak relevan.
- Uji kebocoran cakupan, memastikan daftar *knowledge base* per panggilan tidak dapat dilampaui.
- Penyaring konten wajib di lapisan aplikasi. SEA-LION v4 dirilis tanpa penyelarasan keselamatan, sedangkan audiens produk ini mencakup anak SD, sehingga pengamanan tidak boleh diserahkan kepada model dasar.

8. Risiko dan Mitigasi

Risiko	Mitigasi
Halusinasi pada audiens anak	Contoh negatif pada dataset SFT, kewajiban jawaban berlandaskan potongan konteks, serta evaluasi tingkat penolakan.
Mutu ekstraksi PDF pindaian atau berilustrasi	Jalur OCR melalui model VL dan uji mutu sampel per penerbit. Skala beban diketahui dari hasil triase langkah 1.2.
Kebocoran <i>retrieval</i> antar jenjang	Pembatasan keras daftar <i>knowledge base</i> per panggilan API dan uji kebocoran pada Fase 4.
<i>Trainer</i> belum mendukung Qwen3-VL	Jalur cadangan <i>fine-tuning</i> varian teks.
Kematangan <i>software stack</i> GB10 (arsitektur sm_121 masih baru)	Memakai kerangka yang terverifikasi di DGX Spark (LLaMA-Factory, Unsloth), presisi BF16 konsisten, <i>checkpointing</i> berkala, dan uji coba pelatihan kecil sebelum pelatihan penuh.
Pembaruan kurikulum atau revisi buku	Bukan risiko berdasarkan rancangan. Cukup <i>re-embedding</i> buku terkait tanpa pelatihan ulang.

9. Tindak Lanjut Terdekat

Langkah pertama adalah menjalankan inventarisasi dan triase korpus (langkah 1.1 dan 1.2). Keluarannya berupa katalog metadata lengkap serta rasio buku digital bersih terhadap buku hasil pindaian. Angka rasio tersebut menjadi dasar penentuan kapasitas jalur OCR sebelum jadwal langkah 1.3 sampai 1.5 ditetapkan.