

Rencana Teknis Asisten Belajar Berbasis Korpus Buku Sekolah


Versi ringkas — RAG + SFT di atas SEA-LION 8B · ringkasan dokumen v3, Juli 2026

1. Parameter Kunci

Korpus	~10.000 buku sekolah SD–SMA, ~5 GB
Model dasar	Qwen-SEA-LION-v4-8B-VL (Qwen3-VL-8B-Instruct, konteks 256K)
Platform RAG	RantAI Agents — knowledge base, sitasi bernomor, ekstraksi multimodal
Platform pelatihan	RantAI LLMOps di atas NVIDIA DGX Spark (GB10, unified memory 128 GB)
Metode pelatihan	LoRA BF16. QLoRA tidak dipakai di GB10
Penyimpanan korpus	Object storage S3-compatible (MinIO), sumber tunggal untuk RAG dan training
Deployment	On-premise penuh, tanpa egress ke cloud

2. Prinsip Arsitektur

Pemisahan tegas antara pengetahuan dan perilaku. Isi buku sepenuhnya ditangani RAG; fine-tuning hanya membentuk cara menjawab. Alasannya, bobot model 8B tidak andal menyimpan fakta, tidak menghasilkan sitasi terverifikasi, dan menuntut retraining setiap kali isi buku berubah.




Gambar 1. Pemisahan jalur pengetahuan (RAG) dan perilaku (SFT), dari korpus hingga jawaban.

Lapisan	Solusi	Cakupan
Pengetahuan	RAG pada knowledge base RantAI Agents	Seluruh isi korpus. Update cukup lewat re-embedding, bobot model tidak disentuh.
Perilaku	SFT LoRA BF16 via RantAI LLMOps di GB10	Persona pengajar, format jawaban per jenjang, kewajiban sitasi, penolakan saat konteks kosong.
Model	Qwen-SEA-LION-v4-8B-VL	Konteks 256K untuk banyak potongan retrieval; kemampuan OCR bahasa Indonesia dipakai saat praproses.

3. Knowledge Base dan Pembatasan Cakupan

- Dua belas knowledge base, satu per kelas: sdkelas1–sdkelas6, smpkelas7–smpkelas9, smakelas10–smakelas12. Struktur KB platform masih datar, jadi pemisahan dilakukan lewat konvensi penamaan.
- Relasi dokumen–KB bersifat many-to-many, sehingga satu buku bisa terdaftar di beberapa KB tanpa duplikasi berkas atau re-embedding.
- Satu asisten per kelas dengan whitelist kumulatif pada knowledgeBaseGroupIds — misal asisten "SD Kelas 5" memuat sdkelas1–sdkelas5. Retrieval difilter keras ke daftar itu, sehingga batas antar jenjang bersifat struktural dan dapat diaudit.
- Sitasi bernomor dihasilkan otomatis oleh platform dari metadata potongan (judul, bab, halaman, tipe konten). Citation header eksplisit di tahap praproses bersifat opsional.
- Migrasi ke granularitas per mata pelajaran cukup dengan menautkan ulang dokumen, selama metadata mapel tercatat sejak inventarisasi.



Gambar 2. Alur satu pertanyaan: scoping asisten, retrieval terfilter dan sitasi, hingga lapisan penyaring.

4. Ekstraksi Multimodal: Figur dan Tabel sebagai Aset

- Elemen non-teks tidak diratakan menjadi teks biasa. Setiap potongan diberi penanda jenis (chunkType): teks, tabel, daftar, kode, judul, atau figur.
- Tabel dipertahankan utuh lewat table-aware chunking, sehingga tidak terpotong di tengah baris dan strukturnya tetap terbaca model.
- Figur dan diagram hasil MinerU atau OCR di-crop, diunggah ke object storage dengan assetKey, lalu dipasangkan dengan takarir sebagai potongan yang ikut terindeks — figur bisa muncul sebagai sumber retrieval lengkap dengan nomor halaman.
- Konsekuensinya: pertanyaan yang jawabannya berada di tabel atau gambar tetap terjawab dengan sumber yang tepat, dan jenis potongan menjadi metadata yang dapat difilter saat menyajikan sumber.

5. Penyimpanan Korpus

Layout bucket s3://buku-korpus/ mengikuti tahapan pipeline: raw/ (PDF/EPUB asli), processed/ (Markdown per buku), chunks/ (siap ingest), assets/ (crop figur dan diagram, dirujuk lewat assetKey), sft/ (train.jsonl, eval.jsonl), catalog/ (metadata).

- raw/ bersifat immutable dengan bucket versioning aktif; revisi buku masuk sebagai versi baru.
- Object key membawa metadata, misalnya raw/sma/kelas-10/fisika/{penerbit}-{judul}.pdf.
- Checksum tiap berkas dicatat di katalog untuk deduplikasi dan verifikasi integritas.
- NVMe internal DGX Spark terbatas — data ditarik dari S3 ke disk lokal per job, bukan streaming saat training.

6. Konfigurasi On-Premise

- Embedding qwen3-embedding-8b di-serve lokal; base URL embedding diarahkan ke endpoint sendiri, bukan default OpenRouter.
- Ekstraksi PDF pindaian memakai MinerU sidecar lokal (KB_EXTRACT_MINERU_BASE_URL).
- Fallback OCR berbasis cloud (Mistral OCR, vision-LLM) dinonaktifkan.
- Qwen-SEA-LION di-serve lokal, misalnya via vLLM, dan model routing diarahkan ke endpoint tersebut.

7. Fase Kerja

Fase	Isi	Output
1. Praproses korpus	Inventarisasi 10.000 buku plus metadata mapel; triase format (teks digital, perlu OCR, rusak/duplikat); ekstraksi ke Markdown dengan struktur bab dipertahankan; tabel dipertahankan utuh dan figur di-crop jadi aset bertakarir; pembersihan header, footer, dan duplikat; chunking mengikuti batas subbab, 250–500 token, overlap.	Katalog metadata, rasio digital vs pindaian, ~2,5 juta potongan, audit manual 1–2% sampel per penerbit dan jenjang.
2. Ingest ke knowledge base	Unggah potongan ke dua belas KB sesuai kelas.	Smoke test retrieval 20–30 kueri per jenjang: relevansi potongan, metadata sitasi terbawa, tidak ada kebocoran antar jenjang.
3. Dataset SFT dan pelatihan	Dataset JSONL bergaya percakapan, komposisi 70% data baru : 30% replay. Bagian 70% berisi contoh positif (register dibedakan per jenjang) dengan 10–20% di antaranya contoh negatif berpenolakan halus. Bagian 30% berisi jawaban model SEA-LION baseline sebelum fine-tune, sebagai mitigasi catastrophic forgetting.	Adaptor LoRA BF16: rank 16–32, alpha 2× rank, lr 1e-4–2e-4, 2–3 epoch, AdamW, LLaMA-Factory atau Unsloth, checkpoint tiap 2–3 jam. Durasi beberapa jam sampai satu malam.

Fase	Isi	Output
	Split latih/eval 95:5. Dibuat semi-sintetis, 5–10% sampel diperiksa manual.	
4. Evaluasi dan pengaman	Grounded evaluation di atas eval set yang disisihkan dari dataset asli, bukan benchmark eksternal. Metrik: akurasi jawaban ber-sitasi per jenjang; ketepatan sitasi, yaitu potongan yang dirujuk benar-benar mendukung klaim; refusal rate saat konteks kosong atau tidak relevan; uji kebocoran cakupan antar KB; regression check terhadap baseline SEA-LION pra-fine-tune untuk mendeteksi forgetting.	Content filter di lapisan aplikasi. SEA-LION v4 dirilis tanpa safety alignment dan RantAI Agents belum punya filter konten anak bawaan, jadi komponen ini pekerjaan baru.

8. Keputusan dan Catatan Terbuka

- QLoRA dikeluarkan dari rencana, bukan diturunkan jadi alternatif. Unified memory 128 GB menghilangkan alasan kuantisasi 4-bit, dan ada laporan kemacetan kernel QLoRA 4-bit pada arsitektur sm_121 milik GB10.
- Replay set 30% harus digenerate dari model baseline sebelum training dimulai dan disimpan sebagai artefak tetap, agar regression check pada Fase 4 membandingkan terhadap acuan yang sama sepanjang iterasi.
- Perlu diverifikasi apakah trainer RantAI LLMOps sudah mendukung Qwen3-VL. Bila belum, fallback ke varian teks (Qwen3-8B atau SEA-LION teks) — dataset SFT memang sepenuhnya berbasis teks.

9. Risiko Utama

Risiko	Mitigasi
Halusinasi pada audiens anak	Contoh negatif di dataset SFT, kewajiban menjawab berbasis potongan konteks, evaluasi refusal rate.
Mutu ekstraksi PDF pindaian	Jalur OCR via model VL, uji mutu sampel per penerbit; skala beban diketahui dari triase.
Kebocoran retrieval antar jenjang	Whitelist KB keras per asisten dan uji kebocoran di Fase 4.
Catastrophic forgetting setelah SFT	Replay 30% jawaban baseline dalam dataset, rank LoRA dijaga rendah, dan regression check terhadap baseline pada Fase 4.
Trainer belum mendukung Qwen3-VL	Fallback fine-tuning varian teks.
Kematangan software stack GB10 (sm_121)	Kerangka terverifikasi di DGX Spark, presisi BF16 konsisten, checkpoint berkala, trial run kecil sebelum training penuh.
Revisi kurikulum atau buku	Bukan risiko by design — cukup re-embedding buku terkait.

10. Tindak Lanjut Terdekat

Siapkan object storage dan unggah korpus ke raw/ dengan struktur key sesuai bagian 5, lalu jalankan inventarisasi dan triase. Keluarannya katalog metadata lengkap dan rasio buku digital bersih terhadap hasil pindaian — angka itu menentukan kapasitas jalur OCR sebelum jadwal ekstraksi dan chunking ditetapkan.